

Primena mašinskog učenja u ranoj detekciji kardiovaskularnih bolesti

Katarina Bojović

1 Uvod

U ovom projektnom zadatku obrađen je problem binarne klasifikacije prisustva kardiovaskularne bolesti, na osnovu medicinskih podataka pacijenata. Korišćen je po jedan predstavnik za tri različite grupe klasifikacionih metoda:

- **Parametarska metoda** - logistička regresija, koja pretpostavlja linearnu zavisnost između ulaznih osobina i log-verovatnoće pozitivnog ishoda
- **Neparametarska metoda** - Random Forest, koji ne postavlja pretpostavke o obliku raspodele podataka i omogućava hvatanje nelinearnih odnosa
- **Metoda dubokog učenja** - veštačka neuralna mreža, koja modeluje složene nelinearne odnose u podacima kroz više slojeva transformacija

Cilj je uporediti tačnosti i, još važnije, stopu propuštenih detekcija sva tri modela.


Korišćen je javno dostupan skup podataka *Cardiovascular Disease Dataset* sa platforme Kaggle, koji sadrži podatke o 70 000 pacijenata i binarnu oznaku prisustva bolesti. U fazi pripreme podataka izbačena je kolona *id*, uveden je indeks telesne mase (BMI) i izbačeni su pacijenti sa nekorektnim podacima (njih oko 2%).

Broj redova pre: 70000, posle: 68570

Data columns (total 11 columns):

#	Column	Non-Null Count	Dtype
0	age	68570 non-null	float64
1	gender	68570 non-null	int64
2	bmi	68570 non-null	float64
3	ap_hi	68570 non-null	int64
4	ap_lo	68570 non-null	int64
5	cholesterol	68570 non-null	int64
6	gluc	68570 non-null	int64
7	smoke	68570 non-null	int64
8	alco	68570 non-null	int64
9	active	68570 non-null	int64
10	cardio	68570 non-null	int64

Na slici 1 prikazana je raspodela odbiraka po klasama. Kao što vidimo, klase su skoro pa potpuno izbalansirane. To će nam olakšati dalji rad.



Slika 1: Raspored odbiraka po klasama

1.1 Opis obeležja u datasetu

U korišćenom skupu podataka svaka instanca predstavlja jednog pacijenta, a cilj je da se na osnovu vrednosti navedenih obeležja predvidi prisustvo ili odsustvo kardiovaskularnih bolesti. Tabela 1 prikazuje opis obeležja i njihove moguće vrednosti.


Obeležje	Tip obeležja	Naziv u datasetu	Opis / vrednosti
Starost	Objektivno	age	Celi broj (u godinama)
BMI	Objektivno	bmi	Realan broj
Pol	Objektivno	gender	Kategorijska vrednost (1 = muški, 2 = ženski)
Sistolni pritisak	Pregled	ap_hi	Celi broj (mmHg)
Dijastolni pritisak	Pregled	ap_lo	Celi broj (mmHg)
Holesterol	Pregled	cholesterol	1 = normalan, 2 = povišen, 3 = visok
Glikoza	Pregled	gluc	1 = normalna, 2 = povišena, 3 = visoka
Pušenje	Subjektivno	smoke	Binarno (0 = ne, 1 = da)
Alkohol	Subjektivno	alco	Binarno (0 = ne, 1 = da)
Fizička aktivnost	Subjektivno	active	Binarno (0 = ne, 1 = da)
Prisustvo bolesti	Ciljna promenljiva	cardio	Binarno (0 = zdrav, 1 = bolestan)

Tabela 1: Osnovna obeležja skupa podataka za predikciju kardiovaskularnih bolesti

Prvo ćemo izvršiti **selekciju obeležja** na osnovu informacione dobiti (IG) svakog od njih. Informaciona dobit nekog atributa predstavlja količinu informacija koja se dobija o klasi poznavanjem vrednosti samo tog atributa. Dobijamo sledeće vrednosti:

	obelezje	IG
0	ap_hi	0.155387
1	ap_lo	0.102232
2	age	0.042331
3	cholesterol	0.036582
4	bmi	0.021273
5	gluc	0.006139
6	active	0.001024
7	smoke	0.000196
8	alco	0.000052
9	gender	0.000036

Vidimo da su obeležja `smoke`, `alco` i `gender` prema IG najmanje informativna. Takođe, i njihovi koeficijenti korelacije (Slika 2) sa klasom su najniži, tako da ćemo ih izbaciti.



Slika 2: Matrice koeficijenata korelacije između obeležja

Takođe, sve numeričke kontinualne kolone ćemo standardizovati, čime ćemo ih svesti na istu skalu sa srednjom vrednošću 0 i standardnom devijacijom 1. Diskretne nebinarne numeričke kolone ćemo transformisati u skup binarnih (indikatorskih) promenljivih, tako da svaka kategorija dobije svoju binarnu reprezentaciju. Na taj način sprečavamo da atributi sa većim numeričkim opsegom imaju veći uticaj na proces učenja u odnosu na ostale promenljive.

2 Teorijska motivacija

U medicinskoj klasifikaciji različite greške nemaju istu cenu: proglasiti zdravog pacijenta bolesnim (FP) obično je manje rizično nego proglasiti bolesnog zdravim (FN). U klasičnoj teoriji odlučivanja (Bayesov pristup) to se rešava uvođenjem **različitih cena** za dve vrste grešaka i pomeranjem praga odlučivanja.

U ovom radu ne koristi se eksplicitno Bayesov klasifikator, ali se ista ideja primenjuje na praktičan način:

- uvođenjem parametra `class_weight` pri učenju modela,
- ručnim pomeranjem praga na izlaznim verovatnoćama modela.

3 Korišćene metode mašinskog učenja

Za evaluaciju klasifikatora koristićemo dve metode:

- ROC krivu (AUC) i
- konfuzionu matricu.

ROC kriva (Receiver Operating Characteristic curve) prikazuje odnos između stope tačno pozitivnih detekcija (TPR) i stope lažno pozitivnih detekcija (FPR) za sve moguće pragove odluke. Omogućava vizuelnu procenu koliko dobro model razdvaja klase nezavisno od konkretnog praga.

AUC (Area Under the Curve) predstavlja površinu ispod ROC krive i meri ukupnu sposobnost modela da razlikuje pozitivne i negativne primere. Vrednost $AUC = 0.5$ označava nasumičnu klasifikaciju, dok vrednost bliža 1 označava bolje razdvajanje klasa.

Konfuzionna matrica prikazuje rezultate klasifikacije pri izabranom pragu odluke. Sastoji se od broja tačno pozitivnih (TP), lažno pozitivnih (FP), tačno negativnih (TN) i lažno negativnih (FN) slučajeva. Iz nje se izračunavaju ključne metrike: tačnost, senzitivnost (TPR), specifičnost (TNR), preciznost i stopa lažno negativnih (FNR). Konfuzionna matrica daje konkretnu sliku performansi modela i omogućava izbor praga koji najbolje odgovara kliničkom cilju - u ovom slučaju smanjenju broja propuštenih detekcija bolesti.

3.1 Logistička regresija


Logistička regresija je parametarski model koji procenjuje verovatnoću pripadanja pozitivnoj klasi pomoću sigmoidne funkcije:

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}.$$

gde su $\beta_0, \beta_1, \dots, \beta_n$ parametri (težine) modela.

Prednost logističke regresije je što daje **realne verovatnoće**, pa je lako naknadno pomerati prag i tako smanjiti FNR.

Na slici 3 vidimo ROC krivu i konfuzionu matricu za naš model bez dodatnih podešavanja.



Slika 3: Uporedni prikaz ROC krive i konfuzione matrice


Tačnost: 73.13% Preciznost: 75.82% Senzitivnost: 67.09%
 Specifičnost: 79.04% Stopa lažno negativnih: 32.91%

Vidimo da je klasifikator trenutno zadovoljavajuće tačnosti, ali po cenu prevelikog broja propuštenih detekcija. Pošto je u medicini ključno minimizovati propuštene detekcije (FNR), umesto fiksnog praga na izlaznim verovatnoćama od 0.5, koristićemo nešto niži. Snižavanjem praga povećava se senzitivnost (TPR) i smanjuje FNR, ali povećava broj lažno pozitivnih (pad specifičnosti) i smanjuje tačnost, što je u skladu sa kliničkim prioritetom da se bolest ne propusti. Optimalnu vrednost odredićemo tako što ćemo za niz pragova računati tačnost i FNR na validacionom skupu i izabrati onaj koji obezbeđuje $FNR \leq 15\%$, uz maksimalnu tačnost.

```
th=0.25  FNR=0.05  acc=0.61
th=0.26  FNR=0.05  acc=0.62
th=0.27  FNR=0.06  acc=0.62
th=0.28  FNR=0.07  acc=0.63
th=0.29  FNR=0.08  acc=0.64
th=0.30  FNR=0.09  acc=0.65
```

th=0.31 FNR=0.09 acc=0.65
 th=0.32 FNR=0.10 acc=0.66
 th=0.33 FNR=0.11 acc=0.67
 th=0.34 FNR=0.12 acc=0.68
 th=0.35 FNR=0.13 acc=0.69
 th=0.36 FNR=0.15 acc=0.69


Reći ćemo da nam je optimalan prag na 0.35. Time smo smanjili FNR na validacionom skupu na 13% uz pad ukupne tačnosti na 69%. Na slici 3 prikazana je novodobijena konfuzionna matrica na test skupu i njeni metriki



Slika 4: Optimalna konfuzionna matrica

Tačnost: 68.52% Preciznost: 63.37% Senzitivnost: 86.24%
 Specifičnost: 51.17% Stopa lažno negativnih: 13.76%

Isti efekat može se postići povećavanjem parametra `class_weight` tokom učenja modela, čime model automatski favorizuje pozitivnu klasu. Ponderisanje klasa u odnosu 1:2 dalo je gotovo iste rezultate kao i ručno pomeranje praga na 0.35, i to vidimo na slici 4.



Slika 5: Konfuzionna matrica sa težinama klasa 1:2


Tačnost: 67.92% Preciznost: 62.53% Senzitivnost: 87.75%
 Specifičnost: 48.5% Stopa lažno negativnih: 12.25%

Na osnovu rezultata zaključeno je da dodatno pomeranje praga nakon ponderisanog učenja ne donosi poboljšanje performansi, jer je sam model već optimizovan za smanjenje broja propuštenih slučajeva. Izabrani kompromis (tačnost oko 69% uz $FNR < 15\%$) pokazao se kao najstabilniji i klinički najprihvatljiviji balans između senzitivnosti i tačnosti klasifikacije.

3.2 Random Forest

Random Forest je neparametarska metoda koja kombinuje veliki broj stabala odlučivanja treniranih na nasumičnim podskupovima podataka i atributa. Ovaj model dobro hvata nelinearne odnose između obeležja, pa se često koristi kada su podaci heterogeni i odnosi između promenljivih složeni.

S obzirom da bi bez ponderisanja ili pomeranja praga FNR ponovo bio prevelik, ovoga puta smo odmah prilikom učenja modela primenili ponderisanje klasa u odnosu 1:2. Promenom maksimalne dubine stabala i minimalnog broja uzoraka u listovima dobili smo optimalno rešenje. Na slici 6 vidimo karakteristike dobijenog klasifikatora:




Slika 6: Uporedni prikaz ROC krive i konfuzione matrice

Tačnost: 70.14% Preciznost: 65.17% Senzitivnost: 85.18%
 Specifičnost: 55.41% Stopa lažno negativnih: 14.82%

Ni u ovom slučaju dodatno pomeranje praga nakon ponderisanog učenja ne donosi poboljšanje performansi na test skupu, pa ćemo se zadržati na standardnom pragu.

Odlučeno je da se kao predstavnik neparametarske metode uzme Random Forest, jer za razliku od KNN algoritma, čija vremenska složenost raste proporcionalno sa brojem primera u testiranju (jer se za svaku instancu računa udaljenost do svih ostalih), Random Forest ima znatno manju složenost zahvaljujući već izgrađenim stablima odlučivanja. Ipak, za poređenje je prikazana ROC kriva i konfuziona matrica za **K-Nearest Neighbors (KNN)** klasifikator. Broj suseda k odabran je kao $k = \sqrt{N}$, gde je N broj primera u trening skupu, dok je prag odlučivanja podešen na 0.33 (određen na validacionom skupu).

Kao što vidimo na slici 7, pored veće vremenske složenosti, u ovom slučaju i dobijene metrike su nešto slabije u odnosu na Rain Forest:



Slika 7: Uporedni prikaz ROC krive i konfuzione matrice

Tačnost: 69.40% Preciznost: 64.35% Senzitivnost: 85.56%
 Specifičnost: 53.57% Stopa lažno negativnih: 14.44%

3.3 Veštačke neuralne mreže

Veštačke neuralne mreže predstavljaju klasu modela mašinskog učenja koji mogu da uče nelinearne odnose između ulaznih podataka i izlazne promenljive. Osnovna ideja je da se podaci prosleđuju kroz više uzastopnih slojeva (*layer*) koji sadrže veći broj jednostavnih računskih jedinica (*neurona*). Svaki neuron izračunava ponderisanu sumu ulaza i kroz nelinearnu aktivacionu funkciju (npr. ReLU ili sigmoid) proizvodi izlaz koji se prosleđuje sledećem sloju.

S obzirom da naš dataset nema puno obeležja, korišćen je višeslojni perceptron sa jednim ulaznim slojem, samo jednim skrivenih slojeva od 64 neurona sa ReLU aktivacijom i izlaznim slojem sa sigmoid aktivacijom. Sigmoidna funkcija na izlazu daje vrednost u intervalu $(0, 1)$, što omogućava tumačenje izlaza modela kao verovatnoće da posmatrani pacijent pripada pozitivnoj klasi (ima kardiovaskularnu bolest).


Treniranje mreže vrši se metodom *backpropagation* uz gradijentni spust. U svakom prolazu mreža izračunava izlaz za grupu primera (batch), zatim se izračunava funkcija gubitka – u ovom slučaju `binary_crossentropy`:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N (y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)),$$

gde je y_i stvarna oznaka klase, a $\hat{y}_i$ predikcija mreže. Na osnovu gradijenata gubitka po težinama, parametri mreže se ažuriraju korišćenjem optimizatora Adam.

Kako bi se sprečilo preobučavanje (*overfitting*), u skrivenom sloju je primenjena blaga L2 regularizacija (*weight decay*), kojom se velike vrednosti težina kažnjavaju dodatnim članom u funkciji gubitka. Pored toga, korišćen je i *early stopping*: tokom treniranja prati se validacioni gubitak, i ukoliko se on ne poboljšava određeni broj epoha, treniranje se prekida i vraćaju se najbolje težine.

Na slici 8 prikazane su vrednosti gubitaka na trening i validacionom skupu tokom epohe:




Slika 8: Gubici kroz epohe


Kao što vidimo, i jedna i druga greška sve vreme opadaju, što znači da ne dolazi do preobučavanja.

Pošto izlazna jedinica mreže daje verovatnoću, odluka o klasi se donosi tek nakon izbora praga (najčešće 0.5). U medicinskim zadacima, kao što je naš, često je poželjno spustiti prag kako bi se smanjio broj lažno negativnih slučajeva, čak i po cenu većeg broja lažno pozitivnih.

Za prag postavljen na 0.33 (određen na validacionom skupu) dobijamo karakteristike klasifikatora sa slike 9:



(a) ROC kriva



(b) Optimalna konfuziona matrica

Slika 9: Uporedni prikaz ROC krive i konfuzione matrice

Tačnost: 69.53% Preciznost: 64.58% Senzitivnost: 85.07%
 Specifičnost: 54.30% Stopa lažno negativnih: 14.93%

Uočeno je da veštačka neuronska mreža, iako znatno složenija i vremenski zahtevnija za treniranje, postiže metrike gotovo identične logističkoj regresiji i Random Forest modelu. Ovo ukazuje da je granica razdvajanja klasa u ovom problemu verovatno približno linearna, odnosno da su nelinearnosti u podacima slabe. Drugim rečima, neuralna mreža ne otkriva nove obrasce koje jednostavniji i brži modeli već nisu prepoznali, pa njena upotreba u ovom zadatku nije optimalna.

4 Zaključak

U radu su upoređene tri standardne metode nadgledanog mašinskog učenja za zadatak rane detekcije kardiovaskularnih bolesti. Pokazano je da **nije dovoljno** posmatrati samo ukupnu tačnost, jer model sa tačnošću od oko 73% može da ima i do 33% propuštenih detekcija. Uvođenjem težina klasa i/ili pomeranjem praga odluke moguće je smanjiti FNR na ispod 10–15%, uz prihvatljiv pad tačnosti na 67–70%.

Uzimajući u obzir vrednost AUC, kompromis između tačnosti i stope lažno negativnih slučajeva i brzinu izvođenja, **najbolje rezultate** za ovaj skup podataka pokazao je *Random Forest* model.

Literatura

- [1] S. Sulianova, *Cardiovascular Disease Dataset*, Kaggle, 2019. Dostupno na: <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>
- [2] Ž. Đurović, *Prepoznavanje oblika — skripta uz predmet*, Elektrotehnički fakultet Univerziteta u Beogradu, 2016. Dostupno na: https://automatika.etf.bg.ac.rs/images/FAJLOVI_srpski/predmeti/izborni_kursevi_ostali/OF/OF3SOM/Skripta%20uz%20predmet%20Prepoznavanje%20oblika%20prof.%20Zeljko%20Djurovic.pdf
- [3] *Understanding Logistic Regression in Python*, DataCamp, 2023. Dostupno na: <https://www.datacamp.com/tutorial/understanding-logistic-regression-python>
- [4] *Neural Networks — A Beginner's Guide*, GeeksforGeeks, 2023. Dostupno na: <https://www.geeksforgeeks.org/machine-learning/neural-networks-a-beginners-guide/>